

---

# Proyecto aplicado: Aprendizaje de Máquina aplicado

Marco Teran  
EAFIT  
mtteranl@eafit.edu.co

---

## Resumen

Este proyecto integrador busca que el estudiante ejecute un caso aplicado de *Machine Learning* de principio a fin, siguiendo el marco de trabajo **CRISP-DM**: comprensión del problema, comprensión y preparación de datos, modelado, evaluación rigurosa e interpretación de resultados. El proyecto enfatiza formulación correcta del problema, selección honesta de métricas, *baselines* reproducibles, validación sin fugas de información, comunicación técnica clara y toma de decisiones sustentada en evidencia. La implementación se realizará en **Python** usando *pandas*, *numpy*, *scikit-learn*, y, cuando esté justificado, herramientas adicionales para visualización, interpretabilidad o aprendizaje profundo.

## 1. Introducción

El proyecto aplicado es el eje práctico del curso. Su propósito no es únicamente entrenar un modelo, sino demostrar que el estudiante sabe formular un problema de aprendizaje de máquina, preparar los datos con criterio, construir comparaciones justas entre modelos, evaluar de forma honesta, interpretar hallazgos y traducir resultados en conclusiones útiles.

Se espera un trabajo técnicamente sólido, bien documentado y reproducible. El proyecto debe reflejar buenas prácticas de ciencia de datos aplicada: separación correcta de conjuntos, prevención de *data leakage*, definición de métricas coherentes con el problema, uso de *pipelines*, control experimental, y argumentación clara de cada decisión tomada.

## 2. Objetivos

### 2.1. Objetivo general

Desarrollar un proyecto aplicado de *Machine Learning* siguiendo el flujo de trabajo de **CRISP-DM**, entregando evidencia reproducible, análisis técnico riguroso y conclusiones bien sustentadas.

### 2.2. Objetivos específicos

- Formular correctamente un problema de clasificación, regresión o análisis no supervisado a partir de un conjunto de datos real.
- Caracterizar el conjunto de datos y realizar *EDA* enfocado en calidad, estructura, sesgos, desbalance, fugas potenciales y valor predictivo.
- Construir *baselines* reproducibles y compararlos con modelos más elaborados.
- Implementar *pipelines* de preprocesamiento, entrenamiento y evaluación.
- Comparar al menos dos o tres familias de modelos con una validación metodológicamente correcta.
- Analizar métricas, umbrales, errores, limitaciones y *trade-offs* del modelo final.
- Comunicar resultados mediante un reporte técnico y un producto visual sintético.

## 3. Alcance del proyecto

Cada estudiante o equipo seleccionará un conjunto de datos y formulará un caso de uso concreto. El proyecto

debe responder a una pregunta clara y medible. No se evaluará positivamente el uso de modelos complejos por sí mismos; se evaluará la **pertinencia técnica** de las decisiones. En particular:

- No es obligatorio usar *deep learning*. Solo debe emplearse si el tipo de dato o el problema lo justifica.
- Todo modelo debe compararse con un *baseline* razonable.
- La evaluación debe ser coherente con el tipo de tarea y con el objetivo del problema.
- El proyecto debe poder ser entendido y reproducido por un tercero.

### 3.1. Modalidad de trabajo

El proyecto puede desarrollarse:

- individualmente, o
- en parejas.

No se permitirán equipos de tres personas salvo autorización explícita del profesor.

## 4. Herramientas y entorno sugeridos

La implementación debe realizarse en **Python**, preferiblemente en cuadernos `.ipynb` o en un flujo reproducible equivalente.

**Herramientas sugeridas:**

- `pandas`, `numpy`
- `matplotlib`, `seaborn`
- `scikit-learn`
- `imbalanced-learn`, cuando aplique
- `xgboost`, `lightgbm` o `catboost`, cuando aplique
- `shap` o `permutation importance`, para interpretación
- `TensorFlow/Keras` o `PyTorch`, solo si el problema realmente lo requiere

## 5. Cronograma real del proyecto

El curso se dicta los **jueves** de 6:00 PM a 9:00 PM. Para el periodo del curso, el proyecto se articulará con las siguientes sesiones efectivas:

## 6. Sistema de entregas

El proyecto corresponde al **35 %** de la nota del curso y se divide en tres entregas acumulativas.

| Sesión | Fecha      | Uso pedagógico                                |
|--------|------------|-----------------------------------------------|
| 1      | 19/03/2026 | Lanzamiento del curso y del proyecto          |
| 2      | 26/03/2026 | Formulación del problema y selección de datos |
| –      | 02/04/2026 | Sin clase                                     |
| 3      | 09/04/2026 | Entrega 1                                     |
| 4      | 16/04/2026 | Retroalimentación y avance metodológico       |
| 5      | 23/04/2026 | Modelado y validación                         |
| 6      | 30/04/2026 | Entrega 2                                     |
| 7      | 07/05/2026 | Ajustes finales e interpretación              |
| 8      | 14/05/2026 | Entrega 3 + presentación final                |

### 6.1. Entrega 1: problema, datos, EDA y baseline

**Fecha límite:** 09/04/2026

**Peso:** 5 %

**Objetivo:** demostrar que el equipo comprendió el problema, seleccionó el conjunto de datos adecuadamente y construyó un primer *baseline* reproducible.

**Contenido mínimo:**

**Jupyter Notebook** carga de datos, limpieza inicial, análisis exploratorio, revisión de calidad, definición del problema, variable objetivo, variables de entrada y *baseline* reproducible.

**Data card** descripción breve del conjunto de datos: fuente, tamaño, variables, tipo de tarea, limitaciones y riesgos potenciales.

**Reporte PDF** problema planteado, motivación, breve contexto, descripción de datos, hallazgos del EDA, *baseline* y primeras conclusiones.

**Repositorio Git** estructura inicial organizada y actualizada.

**Debe responder como mínimo:**

- ¿Qué problema intenta resolver?
- ¿Por qué este conjunto de datos es adecuado?
- ¿Qué métrica es razonable y por qué?
- ¿Cuál es el *baseline* y qué tan difícil parece el problema?

### 6.2. Entrega 2: comparación de familias y validación

**Fecha límite:** 30/04/2026

**Peso:** 10 %

**Objetivo:** demostrar comparación técnica seria entre alternativas de modelado.

**Contenido mínimo:**

**Jupyter Notebook** *pipelines* de entrenamiento y evaluación para al menos 2 o 3 familias de modelos.

**Validación** división correcta de datos y validación adecuada al tipo de problema (*holdout*, validación cruzada, validación temporal, etc.).

**Análisis** comparación de métricas, análisis de errores, desbalance, selección de *features*, reducción de dimensionalidad o ajuste de umbral cuando aplique.

**Reporte PDF** metodología, configuración experimental, resultados comparativos, discusión técnica y decisión provisional.

**Repositorio Git** actualizado, ordenado y coherente con el reporte.

**Debe responder como mínimo:**

- ¿Qué modelos se compararon y por qué?
- ¿Cómo se evitó el *data leakage*?
- ¿Cuál familia parece más prometedora?
- ¿Qué limitaciones siguen abiertas?

### 6.3. Entrega 3: modelo final, interpretación y comunicación

**Fecha límite:** 14/05/2026

**Peso:** 20 %

**Objetivo:** entregar la versión final del proyecto con análisis integral, interpretación y comunicación de hallazgos.

**Contenido mínimo:**

**Jupyter Notebook** modelo final reproducible, evaluación final, interpretación, análisis de sensibilidad o errores, y justificación de decisiones.

**Reporte PDF** versión final del artículo o informe ejecutivo con resumen, metodología, resultados, discusión, limitaciones y recomendaciones.

**Póster PDF** síntesis visual del problema, método y resultados clave.

**Repositorio Git** definitivo, limpio y navegable.

**Presentación corta** exposición final en clase del proyecto.

**Debe responder como mínimo:**

- ¿Cuál es el mejor modelo y por qué?
- ¿Qué tan confiables son sus resultados?
- ¿Qué variables o patrones explican el desempeño?
- ¿Qué conclusiones útiles deja el proyecto?
- ¿Qué haría falta para mejorar o desplegar la solución?

## 7. Criterios de evaluación del proyecto

## 8. Conjuntos de datos sugeridos

La elección del conjunto de datos debe responder a una pregunta clara y a un alcance viable para el curso. Se recomienda seleccionar un dataset que permita

| Criterio                                               | Peso |
|--------------------------------------------------------|------|
| Formulación del problema y claridad del objetivo       | 10 % |
| Calidad del EDA y comprensión del conjunto de datos    | 15 % |
| Rigor experimental y validación honesta                | 20 % |
| Calidad de <i>baselines</i> y comparación de modelos   | 15 % |
| Interpretación de resultados y discusión crítica       | 15 % |
| Reproducibilidad, orden del repositorio y trazabilidad | 10 % |
| Calidad del reporte, póster y comunicación final       | 15 % |

construir un *baseline* razonable, comparar al menos dos familias de modelos y justificar métricas y validación de forma honesta.

A continuación se propone una lista curada de datasets con mejor valor pedagógico para el curso, junto con tipos de solución recomendados.

#### ■ Adult / Census Income [\[acceder\]](#)

**Problema sugerido:** clasificación binaria.

**Pregunta posible:** predecir si el ingreso anual supera cierto umbral.

**Soluciones sugeridas:**

- modelos lineales y regresión logística;
- árboles, Random Forest, XGBoost o LightGBM;
- análisis de *fairness*, sesgo y explicabilidad;
- comparación entre variables categóricas codificadas y *pipelines* mixtos.

#### ■ Bank Marketing [\[acceder\]](#)

**Problema sugerido:** clasificación binaria.

**Pregunta posible:** predecir si un cliente aceptará un depósito a término.

**Soluciones sugeridas:**

- regresión logística, SVM, árboles y ensambles;
- análisis de desbalance moderado y ajuste de umbral;
- interpretabilidad con importancia de variables o SHAP;
- comparación entre métricas como accuracy, F1, ROC-AUC y PR-AUC.

#### ■ California Housing [\[acceder\]](#)

**Problema sugerido:** regresión.

**Pregunta posible:** estimar el valor medio de vivienda a partir de variables socioeconómicas y geográficas.

**Soluciones sugeridas:**

- regresión lineal, Ridge, Lasso y Elastic Net;

- árboles, Random Forest, Gradient Boosting, XGBoost;
  - selección de variables, regularización e interpretación de error;
  - análisis espacial simple y *feature engineering* geográfico.
- **Credit Card Fraud Detection** [\[acceder\]](#)  
**Problema sugerido:** clasificación desbalanceada o detección de anomalías.  
**Pregunta posible:** detectar transacciones fraudulentas con bajo número de positivos.  
**Soluciones sugeridas:**
- regresión logística con *class weights*;
  - Random Forest, XGBoost, LightGBM;
  - técnicas de desbalance como undersampling, oversampling o SMOTE solo en entrenamiento;
  - ajuste de umbral, PR-AUC, recall, costo de error;
  - enfoque opcional de *anomaly detection* o auto-encoder si se justifica.
- **Online Retail** [\[acceder\]](#)  
**Problema sugerido:** clustering, segmentación, análisis transaccional o recomendación simple.  
**Pregunta posible:** segmentar clientes, identificar patrones de compra o construir recomendaciones básicas.  
**Soluciones sugeridas:**
- RFM + clustering (*k*-means, jerárquico, DBSCAN);
  - reducción de dimensionalidad con PCA o UMAP para visualización;
  - reglas de asociación o canasta de mercado;
  - recomendación sencilla basada en co-ocurrencia o vecindad.
- **M5 Forecasting - Accuracy** [\[acceder\]](#)  
**Problema sugerido:** series de tiempo y pronóstico multiserie.  
**Pregunta posible:** predecir ventas futuras usando historia, calendario y variables de precio.  
**Soluciones sugeridas:**
- *baselines* de persistencia, promedio móvil o estacional;
  - *feature engineering* temporal con rezagos y ventanas;
  - modelos tabulares para series de tiempo con XGBoost o LightGBM;
  - comparación con enfoques de *deep learning* solo si el equipo tiene capacidad;
  - validación temporal estricta.
- **Fashion-MNIST** [\[acceder\]](#)  
**Problema sugerido:** clasificación de imágenes.
- Pregunta posible:** clasificar prendas de vestir a partir de imágenes en escala de grises.  
**Soluciones sugeridas:**
- *baselines* con MLP o SVM sobre píxeles vectorizados;
  - CNN como solución principal de *deep learning*;
  - comparación entre enfoque clásico y enfoque profundo;
  - análisis de errores por clase y matriz de confusión.
- **IMDb Reviews** [\[acceder\]](#)  
**Problema sugerido:** clasificación de texto / análisis de sentimiento.  
**Pregunta posible:** clasificar reseñas positivas y negativas.  
**Soluciones sugeridas:**
- bolsa de palabras o TF-IDF + regresión logística o SVM;
  - embeddings y clasificadores lineales;
  - *transformers* finos para clasificación;
  - comparación exploratoria con LLMs vía *zero-shot classification*, resumen o extracción de argumentos;
  - análisis de errores lingüísticos y longitud de texto.
- **AG News** [\[acceder\]](#)  
**Problema sugerido:** clasificación multiclase de texto.  
**Pregunta posible:** clasificar noticias por tema.  
**Soluciones sugeridas:**
- TF-IDF + regresión logística o SVM;
  - *transformers* para clasificación multiclase;
  - embeddings semánticos + clasificador ligero;
  - LLMs para *zero-shot* o *few-shot classification*;
  - visualización de clases, confusión y análisis de ambigüedad temática.
- **MovieLens 100K** [\[acceder\]](#)  
**Problema sugerido:** sistemas de recomendación.  
**Pregunta posible:** recomendar películas o predecir puntuaciones.  
**Soluciones sugeridas:**
- filtrado colaborativo basado en usuarios o ítems;
  - factorización matricial;
  - modelos de ranking o recomendación top-*k*;
  - evaluación con métricas de recomendación, no solo RMSE.
- **UJIIndoorLoc** [\[acceder\]](#)  
**Problema sugerido:** clasificación, regresión o problema jerárquico de localización indoor.  
**Pregunta posible:** predecir edificio, piso o coordenadas a partir de huellas WiFi.

#### Soluciones sugeridas:

- clasificación por edificio/piso y regresión posterior para coordenadas;
- KNN, Random Forest, Gradient Boosting, SVM o MLP;
- comparación entre enfoque jerárquico y enfoque directo;
- reducción de dimensionalidad y análisis de *sparsity*.

### 8.1. Criterios para escoger el dataset

Se recomienda elegir un dataset que:

- tenga una pregunta clara y una variable objetivo bien definida;
- permita construir un *baseline* razonable;
- sea viable de trabajar dentro del tiempo del curso;
- no dependa de infraestructura desproporcionada;
- permita comparar modelos y justificar métricas;
- tenga suficiente riqueza para generar conclusiones útiles.

### 8.2. Recomendación de elección según nivel de ambición

- **Ruta conservadora y sólida:** Adult, Bank Marketing, California Housing.
- **Ruta intermedia con mayor reto:** Credit Card Fraud, Online Retail, UJIIndoorLoc.
- **Ruta avanzada:** M5 Forecasting, Fashion-MNIST con CNN, IMDb o AG News con transformers/LLMs, MovieLens con recomendación.

### 8.3. Propuesta de dataset propio

También puede proponerse un conjunto de datos distinto, siempre que:

- sea accesible y documentable;
- tenga suficiente tamaño o complejidad;
- permita una tarea clara de ML;
- no exija infraestructura desproporcionada para el curso;
- sea aprobado por el profesor a más tardar en la sesión 2.

## 9. Formato y requisitos de entrega

#### Requisitos generales.

- Cada entrega debe enviarse en un único archivo .zip.
- Nombre sugerido: ml-proj-apellidos.zip.

- La entrega debe realizarse antes de las 11:59 PM de la fecha límite correspondiente.
- No incluya datos pesados innecesarios ni binarios prescindibles.

#### Estructura mínima sugerida del repositorio.

```
project/  
  README.md  
  data/  
  notebooks/  
  src/ % opcional  
  figures/  
  report/  
  poster/  
  requirements.txt % o environment.yml
```

#### Buenas prácticas obligatorias.

- Fije semillas cuando aplique.
- Separe claramente entrenamiento, validación y prueba.
- Justifique todas las transformaciones de datos.
- Documente limitaciones, supuestos y decisiones.
- Incluya instrucciones mínimas para reproducir resultados.

## 10. Qué se considera un buen proyecto

- Tiene una pregunta clara y una variable objetivo bien definida.
- Usa una métrica apropiada para el tipo de decisión que se quiere tomar.
- Tiene una narrativa técnica coherente.
- Compara alternativas razonables y no solo un único modelo.
- Reconoce sus limitaciones y evita afirmaciones exageradas.
- Produce conclusiones útiles, no solo números.

## 11. Qué se considera un proyecto débil

- Problema mal formulado o sin objetivo claro.
- Métricas elegidas sin justificación.
- Uso de modelos complejos sin *baseline*.
- Validación defectuosa o con fuga de información.
- Reporte sin análisis crítico, solo descriptivo.
- Repositorio desordenado o irreproducible.

## 12. Recomendaciones

- Planifique el trabajo por etapas y no deje la validación para el final.
- Empiece por un problema comprensible y técnicamente viable.
- Prefiera un buen proyecto bien ejecutado a uno muy ambicioso pero débil.
- Revise métricas, desbalance, sesgos y errores con criterio.
- Mantenga coherencia entre problema, datos, modelo y conclusión.
- Documente todo con honestidad técnica.

## 13. Bibliografía y referencias sugeridas

- **IBM.** *CRISP-DM 1.0: Step-by-step data mining guide.*
- **Hastie, Tibshirani y Friedman.** *The Elements of Statistical Learning.* Springer.
- **James, Witten, Hastie y Tibshirani.** *An Introduction to Statistical Learning.*
- **Bishop.** *Pattern Recognition and Machine Learning.* Springer.
- **scikit-learn** documentation. <https://scikit-learn.org/>